



Alma Mater Studiorum · Università di Bologna

Dipartimento dell'energia elettrica e dell'informazione
«Guglielmo Marconi»

Predictive Modeling of Grapevine Growth: Estimating Development Over Time

Presentata da:
Abess Ouardi

Relatore:
Lorenzo Marconi

Anno accademico 2023/2024
Sessione V

Approcci esistenti

◆ PBCMs

- Basato su fisiologia reale
- Interpretabile
- Buona generalizzazione
- Nessuna rappresentazione della forma
- Richiede parametrizzazione precisa

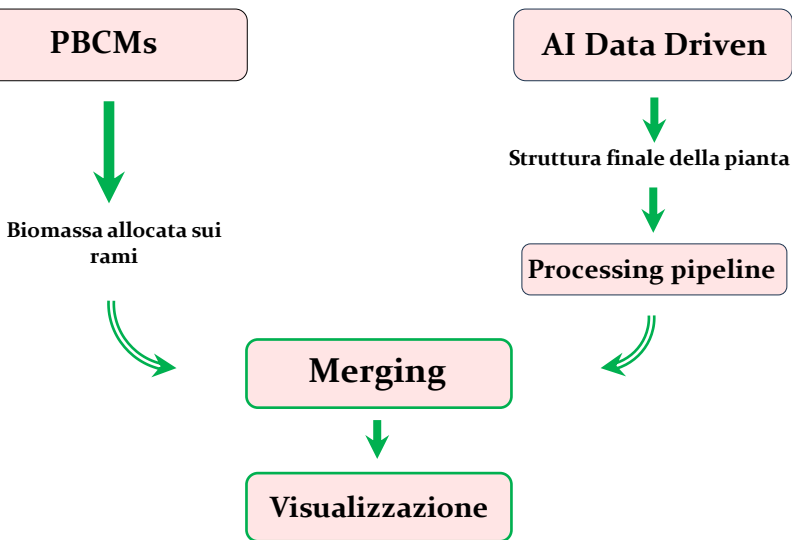
◆ FSPMs

- Rappresentazione strutturale dettagliata
- Legame tra fisiologia e geometria
- Complessità computazionale
- Alta richiesta di dati e parametrizzazione


◆ AI driven

- Nessuna assunzione biologica
- Addestrabile su grandi dataset
- Predizione visiva
- Scarsa interpretabilità
- Generalizzazione limitata
- Richiede molti dati

Visione del framework ibrido implementato



PBCM: processi modellati & implementazione



Input richiesti

Temperatura

- ARPAE Emilia Romagna
- Data , Tmin, Tmax, Precipitazioni

Concentrazione di anidride carbonica

- ARPAE Emilia Romagna
- Data ,value [part per million]

Umidità del suolo

- AI generated
- Data ,Soil Moisture (%)

radiazione solare

- AI generated
- Data , Light Intensity (MJ/m²)

Fenologia

♦ GDD (Growing Degree Days)

Il GDD è un approccio che consente di calcolare l'occorrenza dei stati fenologici della pianta mediante la seguente:

$$GDD = T_{average} - T_{base}$$

STATO FENOLOGICO	GDD	T_{base}
Germogliamento	114	6,5°C
Fioritura	354	8,2°C
invaiaura	727	9,7°C
Maturazione	1267	10°C

♦ Chilling-forcing units

Il metodo Chilling–Forcing Units combina l'accumulo di freddo invernale (chilling) con il successivo accumulo di calore primaverile (forcing) per stimare l'occorrenza del germogliamento.


$$CU = \sum_i f(T_i)$$

$$FU = \sum_i \max(0, T_{mean} - T_{base})$$


STATO FENOLOGICO	CU	FU	T_{base}
Germogliamento	78	198	6,5°C


Fotosintesi

Il modello calcola giornalmente la fotosintesi netta sulla base dell'intensità luminosa incidente, la concentrazione atmosferica di CO₂ e la temperatura. I valori giornalieri vengono integrati moltiplicandoli per l'indice di area fogliare (LAI) e un coefficiente di efficienza


$$\text{LeafNumberRate} = \text{SLN1} + \text{LAR1} * T_{\text{average}} * \text{ShootLeafNumber} * \text{LAS}$$


$$\text{PlantLeafArea} = \text{SLAS} * (\text{LeafNumberRate})^{\text{SLAE}} * \text{ShootNumber}$$


$$\text{LAI} = \frac{\text{PlantLeafArea} * \text{PSA}}{\text{PlantArea} * 10000}$$


$$\text{RadIntercepted} = 1 - e^{-(\text{CropCoefficient} - \text{LAI})}$$

Biomassa e relativa allocazione

La biomassa è prodotta dalla fotosintesi in funzione della radiazione intercettata e dell'efficienza d'uso della radiazione (RUE), quest'ultima è funzione sia della temperatura che della concentrazione di CO₂ nell'aria

$$PhotoRate = GSR * RadIntercepted * RUE * PhotoStress$$

$$TotBiomass = TotBiomass + PhotoRate$$

Il totale è allocato dinamicamente in funzione dello stato fenologico della pianta:


STATO FENOLOGICO	Biomassa fogliare	Biomassa del frutto	Biomassa dei tralci
Germogliamento	10%	0%	90%
Fioritura	60%	0%	40%
Invaiaura	$(TotBio-FB)*0,7$	$FB = TotBio * \sum HI * FSI$	$(TotBio-FB)*0,3$
Maturazione	$(TotBio-FB)*0,8$	$FB = TotBio * \sum HI * FSI$	$(TotBio-FB)*0,2$

Deep Neural Networks

Le Deep Neural Networks (DNN), o reti neurali profonde, sono una classe di modelli di apprendimento automatico composti da una sequenza di strati (layers) interconnessi, progettati per apprendere rappresentazioni gerarchiche dei dati.

A seconda del tipo di dati e problema, esistono architetture specializzate:

- MLP
- RNN
- CNN
- LSTM
- Autoencoder
- Transformer
- GAN




Una GAN condizionata: Pix2Pix

Le Generative Adversarial Networks (GAN) sono una classe di reti neurali profonde composte da due reti: un Generatore G e un discriminatore D.

Le due reti sono addestrate contemporaneamente in un gioco a somma zero descritto dalla seguente:

$$\min \max V(D, G) = E_{x \sim p_{data}} [\log D(x)] + E_{z \sim p_z} [\log (1 - D(G(z)))]$$

La Pix2Pix GAN è una particolare architettura di GAN condizionata sviluppata per risolvere problemi di Image-to-Image Translation. Il generatore è una U-Net mentre il discriminatore è una PatchGAN.



Dataset

Il dataset utilizzato proviene dal repository open-source Buds-Dataset e contiene un totale di 98 immagini.



Dataset

- Il dataset utilizzato proviene dal repository open-source Buds-Dataset e contiene un totale di 98 immagini.
- Per simulare una situazione post-potatura le immagini sono state binarizzate e modificate tramite photo editors



Dataset

- Il dataset utilizzato proviene dal repository open-source Buds-Dataset e contiene un totale di 98 immagini.
- Per simulare una situazione post-potatura le immagini sono state binarizzate e modificate tramite photo editors
- Il dataset è stato suddiviso in:
 - 78 pic per training
 - 10 pic per la validazione
 - 10 pic per il testing
- Per aumentare la varietà del training dataset e migliorare la generalizzazione del modello è stato effettuato un processo di data Augmentation.



Dataset

Il dataset utilizzato proviene dal repository open-source Buds-Dataset e contiene un totale di 98 immagini.


Per simulare una situazione post-potatura le immagini sono state binarizzate e modificate tramite photo editors

Il dataset è stato suddiviso in:

- 78 pic per training
- 10 pic per la validazione
- 10 pic per il testing

Per aumentare la varietà del training dataset e migliorare la generalizzazione del modello è stato effettuato un processo di data Augmentation.

Per compatibilità con l'architettura, le immagini sono state ridimensionate a 256x256

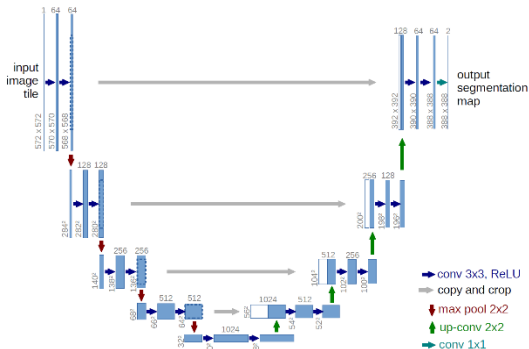


U-net come Generatore

La U-Net è una rete neurale composta da due parti principali, che formano graficamente una “U”


- Encoder (contrazione); costituito da una serie di blocchi convoluzionali seguiti da layer d’attivazione (ReLU) e Pooling layers
- Decoder (espansione); serie di Up-convolutions per ricostruire l’immagine

La caratteristica principale di queste reti è la presenza delle Skip Connections, fondamentali per preservare la geometria dell’immagine



PatchGAN come Discriminatore

Il PatchGAN è un tipo di discriminatore utilizzato nelle architetture GAN che, invece di classificare l'intera immagine come reale o falsa, si focalizza sulla valutazione locale della realistica, analizzando porzioni (patches) dell'immagine.



Loss functions & Training

Le funzioni di perdita (o funzioni obiettivo) sono formule matematiche utilizzate per misurare quanto l'output di un modello differisce dal risultato atteso. L'obiettivo del modello è minimizzare la funzione di perdita o come in questo caso una combinazione di varie loss functions:

- Adversarial loss
- SSIM loss
- Dice loss
- Edge loss

$$L_{tot} = \lambda_{adv} * L_{adv} + \lambda_{SSIM} * L_{SSIM} + \lambda_{dice} * L_{dice} + \lambda_{edge} * L_{edge}$$


L'addestramento è stato condotto su batch di 12 immagini, per un totale di 200 epoche, con ottimizzazione tramite algoritmo Adam. I coefficienti delle loss sono stati adattati ogni 10-30 epoche sulla base dell'andamento delle metriche di valutazione, al fine di migliorare la coerenza strutturale e la nitidezza delle predizioni.

Risultati


Il modello presenta un SSIM score nel training set pari a 0,92 e un Dice score pari a 0,87. Invece nel test set i valori sono inferiori pari a 0,81 ($\pm 0,07$) per il SSIM score e un valore pari a 0,74 ($\pm 0,05$) per il Dice score.

Esempi di predizione sulle immagini di test:


96



37



20



Integrazione degli output

Lo scopo del merging è integrare i dati numerici generati dal modello fisiologico (PBCM), che simula l'accumulo di biomassa, con le immagini strutturali generate dal modello GAN, che predice la morfologia della pianta a fine stagione

L'output della GAN è inizialmente un'immagine che presenta rumore e artefatti visivi. Si applicano quindi vari passaggi di preprocessing descritti dalla seguente pipeline:

Binarizzazione

**Rimozione del
rumore**




**Riassegnazione
dei colori**

**Upscaling e
downscaling**



Visual

Per integrare dati fisiologici privi di spazialità con una struttura visiva generata, è stato necessario tradurre la biomassa simulata in pixel attivabili, permettendo così una rappresentazione temporale e morfologica coerente della crescita della pianta.



Conclusione e sviluppi futuri

Il lavoro presentato ha dimostrato la possibilità di integrare con successo due approcci distinti — fisiologico e strutturale — per la modellazione della crescita della vite. Attraverso l'unione di un modello process-based (PBCM), in grado di simulare l'accumulo di biomassa sulla base di parametri ambientali, e un modulo generativo (Pix2Pix GAN), capace di predire la morfologia della pianta a fine stagione

Possibili sviluppi futuri:

- Espansione del Dataset
- Validazione sperimentale sul campo
- Integrazione con dati real time (IoT)
- Modellizzazione di ulteriori processi fisiologici



Alma Mater Studiorum · Università di Bologna

Dipartimento dell'energia elettrica e dell'informazione
«Guglielmo Marconi»

Grazie per l'attenzione